

Progress 2

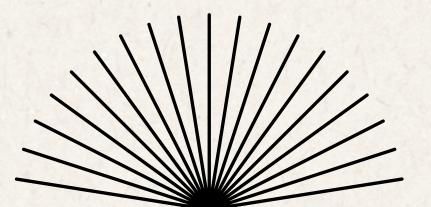
PROYEK TKTI 2025

RENCANA JUDUL:

**Intelligent Project
Management Workflow
Automation Using N8N and
Machine Learning**

PRESENTED BY:

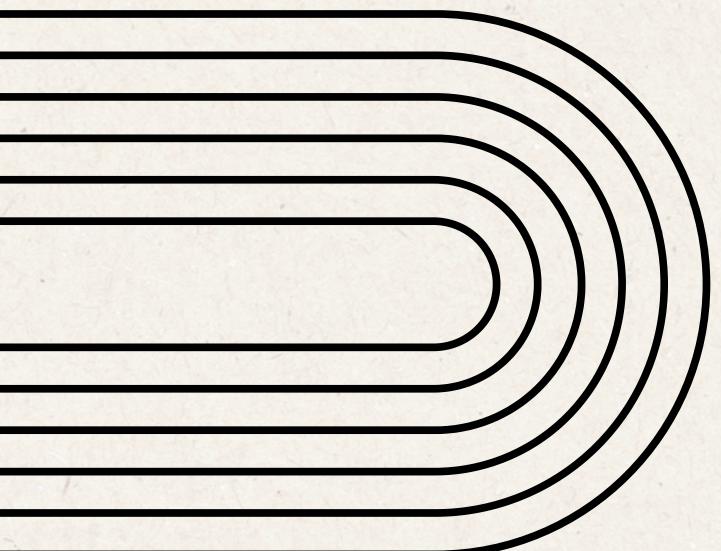
Muhammad Risyad Himawan Putra
5025231205

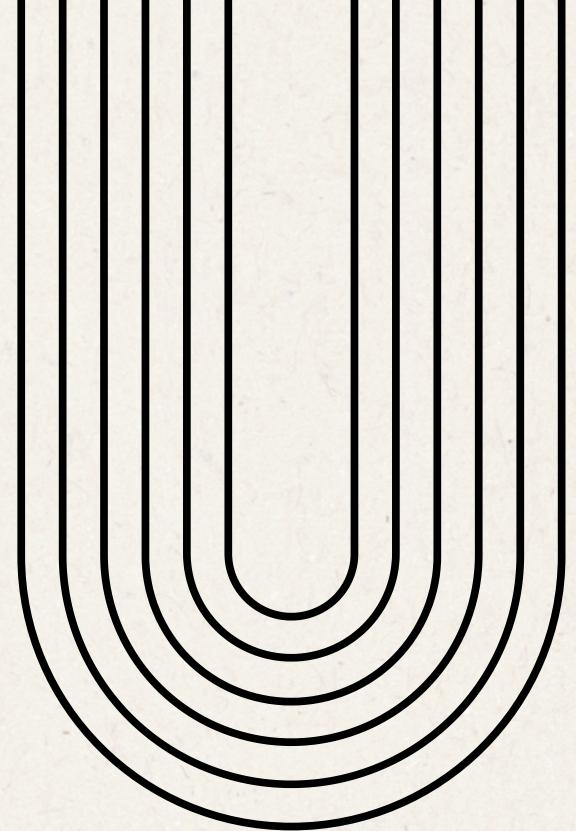


Executive Summary

Latar Belakang

Organisasi sering mengalami keterlambatan tugas, distribusi beban kerja yang tidak merata, dan estimasi deadline/biaya yang kurang akurat. Proyek ini menggabungkan workflow automation (n8n) dengan model-machine learning untuk membuat alur kerja manajemen proyek yang efisien, dengan otomatisasi penugasan, prediksi batas waktu, dan alokasi sumber daya.

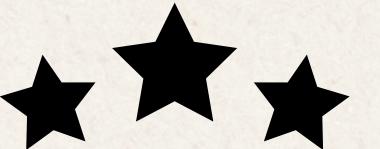




Tujuan

- 01** Membangun pipeline ML yang terintegrasi dengan n8n untuk assignment otomatis, prediksi deadline, rekomendasi alokasi resource.
- 02** Evaluasi model (MAE/MAPE/Precision/Akurasi) serta interpretabilitas (SHAP/LIME).

Kontribusi



1

Integrasi end-to-end antara n8n dan model ML (deployment & automation).



2

Kombinasi model supervised (RF/XGBoost untuk assignment), time-series / sequence (LSTM/DNN untuk deadline), dan optimisasi alokasi (RL/LP).



3

Analisis XAI (Explainable AI) untuk transparansi keputusan.

Problem Statement

#1 Keterlambatan (delays)

Tugas sering selesai melewati jadwal; perlu prediksi dan pencegahan dini.

#2 Penugasan sub-optimal

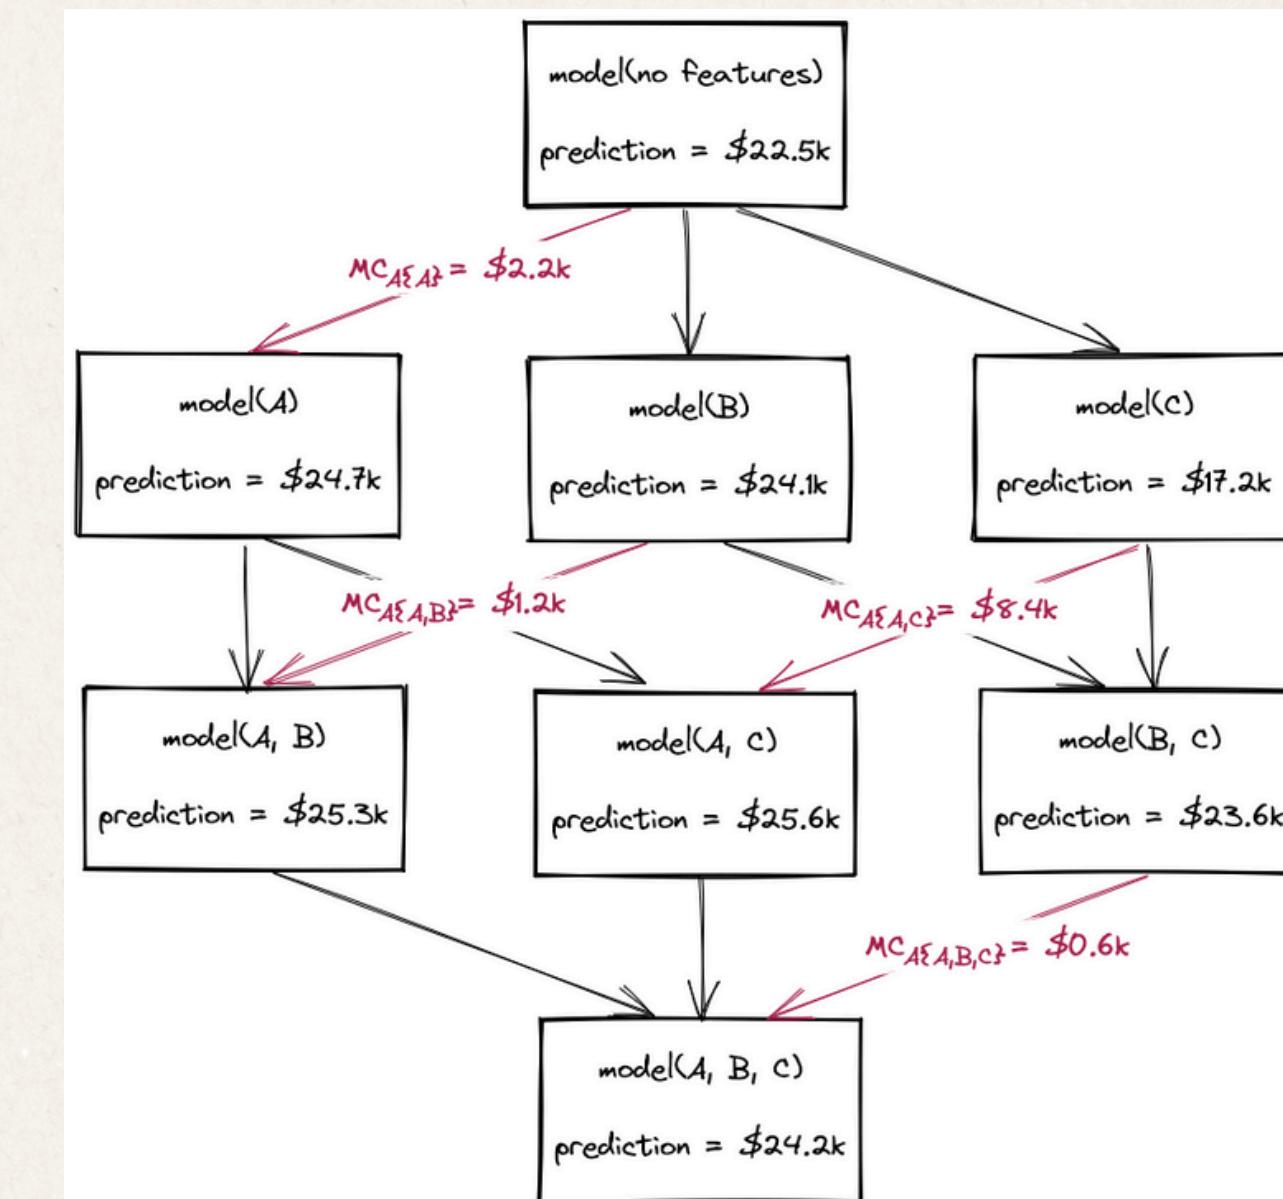
Siapa yang harus diberi tugas agar beban merata dan efisien?

#3 Alokasi sumber daya & biaya

Bagaimana membagi jam kerja dan anggaran agar deviasi minimal?

#4 Kurangnya transparansi

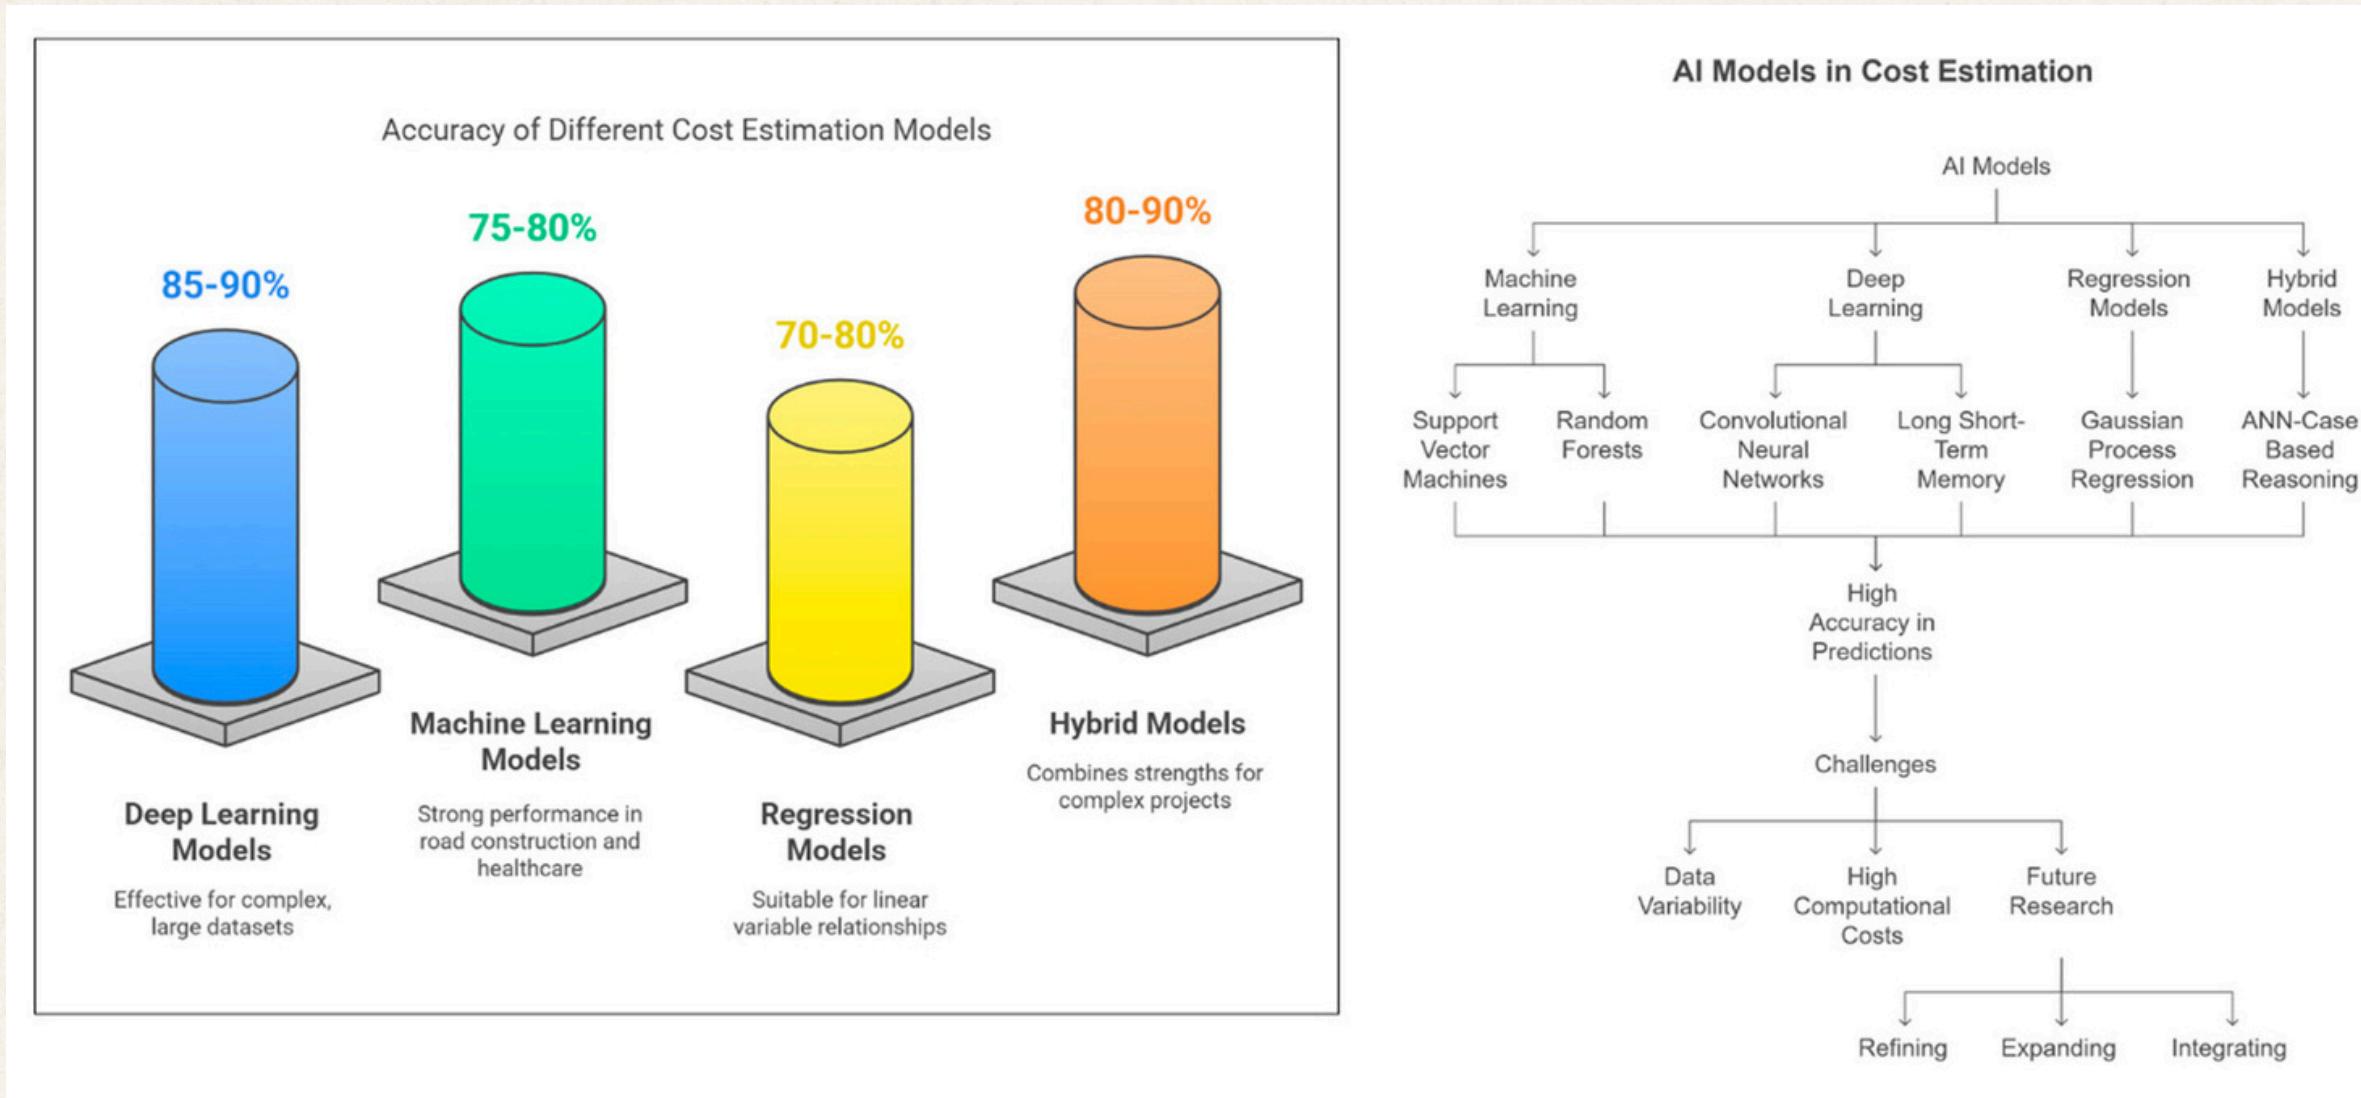
Manajer butuh alasan (feature importance) untuk rekomendasi otomatis.



Penggambaran SHAP dengan marginal contributions antar modelnya.

Referensi 1

Advancement of Artificial Intelligence in Cost Estimation for Project Management Success: A Systematic Review of Machine Learning, Deep Learning, Regression, and Hybrid Models



Kajian ini merangkum perkembangan estimasi biaya dalam project management dari metode manual ke AI yang lebih akurat dan efisien. Berbagai algoritma seperti Machine Learning (ML), Deep Learning (DL) (seperti ANN, CNN, LSTM), serta model hibrida (misalnya CBR-ANN) secara signifikan meningkatkan akurasi prediksi biaya hingga 85-99% di berbagai industri.

Keterbatasan utama mencakup kualitas dan variasi data, kebutuhan dataset besar, serta biaya komputasi tinggi. Untuk meningkatkan kepercayaan pengguna, dibutuhkan model yang transparan dengan pendekatan Explainable AI (XAI), seperti SHAP untuk menjelaskan kontribusi setiap variabel. Penelitian ke depan perlu memperluas dataset dan mengintegrasikan faktor eksternal seperti harga material dan biaya tenaga kerja.

Referensi 2

Explainable machine learning for project management control

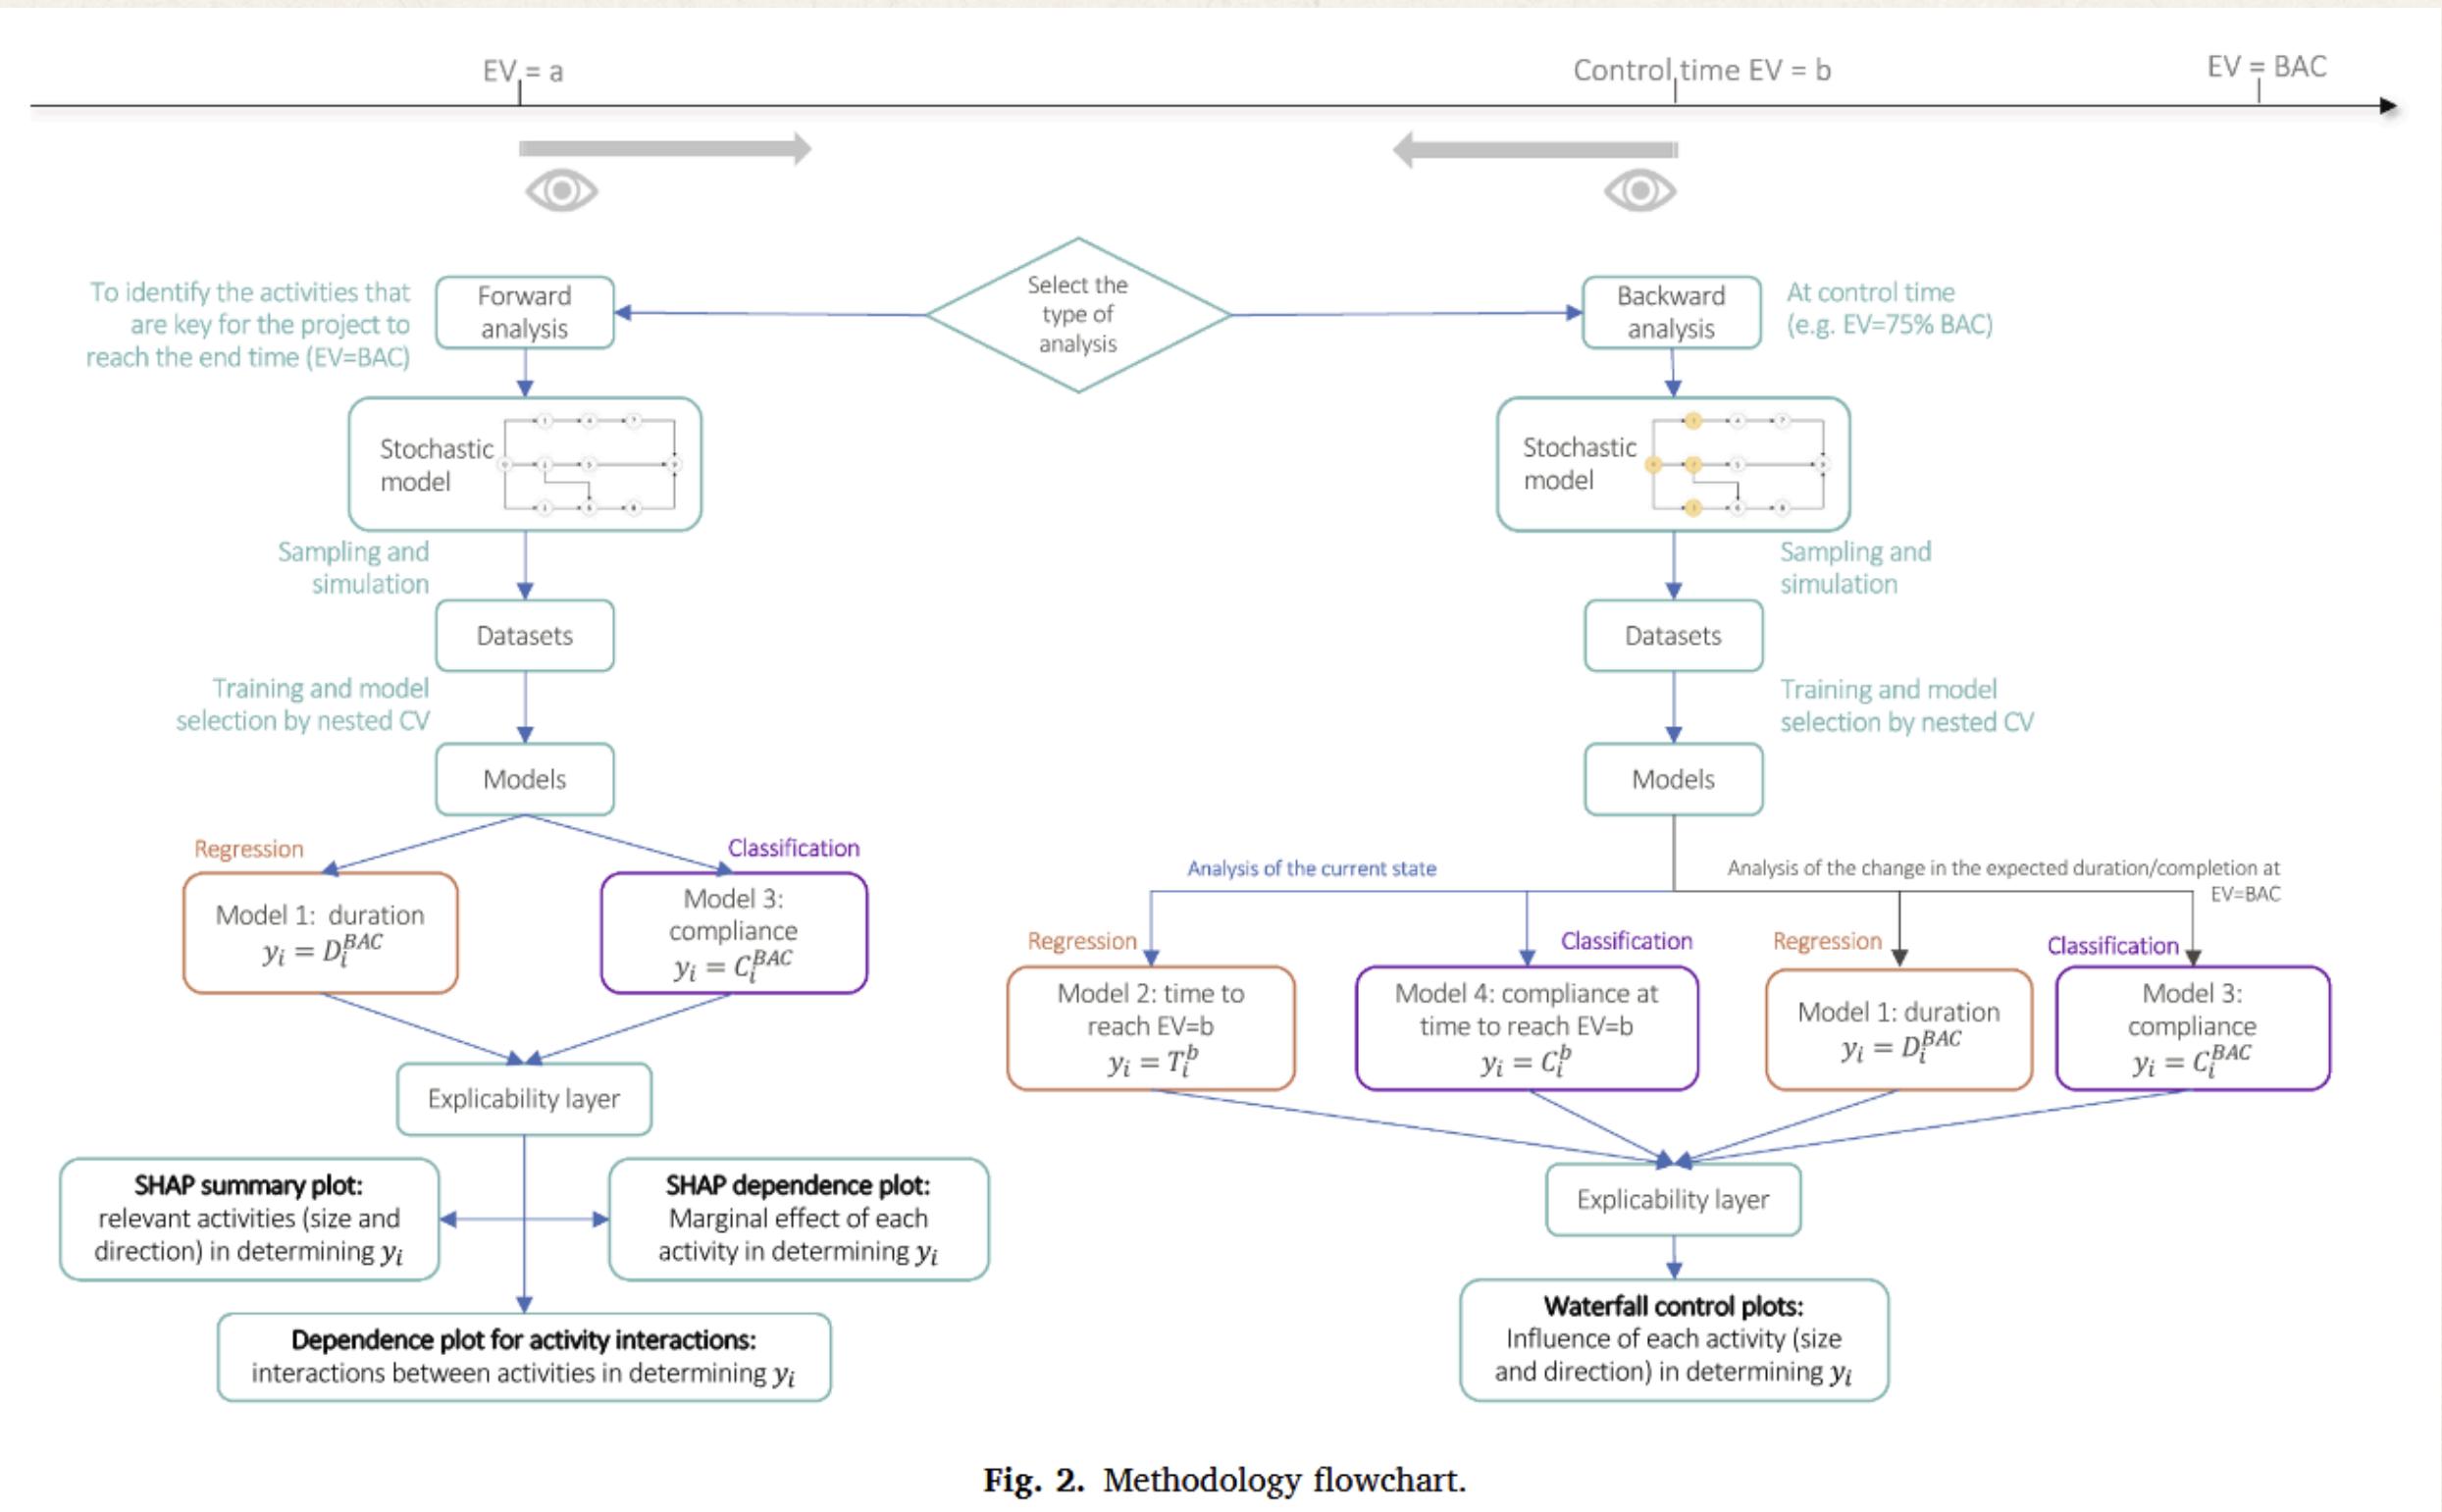


Fig. 2. Methodology flowchart.

Penelitian ini memperkenalkan metodologi baru untuk pengendalian proyek dengan variabilitas stokastik berbasis Earned Value Management (EVM) dan triad methods, memanfaatkan Monte Carlo simulation, machine learning, dan teknik Explainable AI (XAI) seperti SHAP. Metode ini menyediakan dua framework analysis:

1. **Forward analysis:** Menggunakan simulasi dan model ML untuk memahami pengaruh aktivitas proyek terhadap durasi dan probabilitas penyelesaian tepat waktu, dengan visualisasi SHAP (summary plot, dependence plot) untuk mengidentifikasi aktivitas paling kritis.
2. **Backward analysis:** Menggunakan data progres aktual untuk memprediksi perubahan ekspektasi proyek dan menganalisis penyebabnya, membantu project manager mengendalikan dan mengatribusikan tanggung jawab perkembangan proyek secara adil.

Referensi 3

Software Project Management Using Machine Learning Technique—A Review

2.3. Software Project Management Estimation Based on ML

Figure 1 illustrates the procedure of software project management estimation, which can be summarized, as follows.

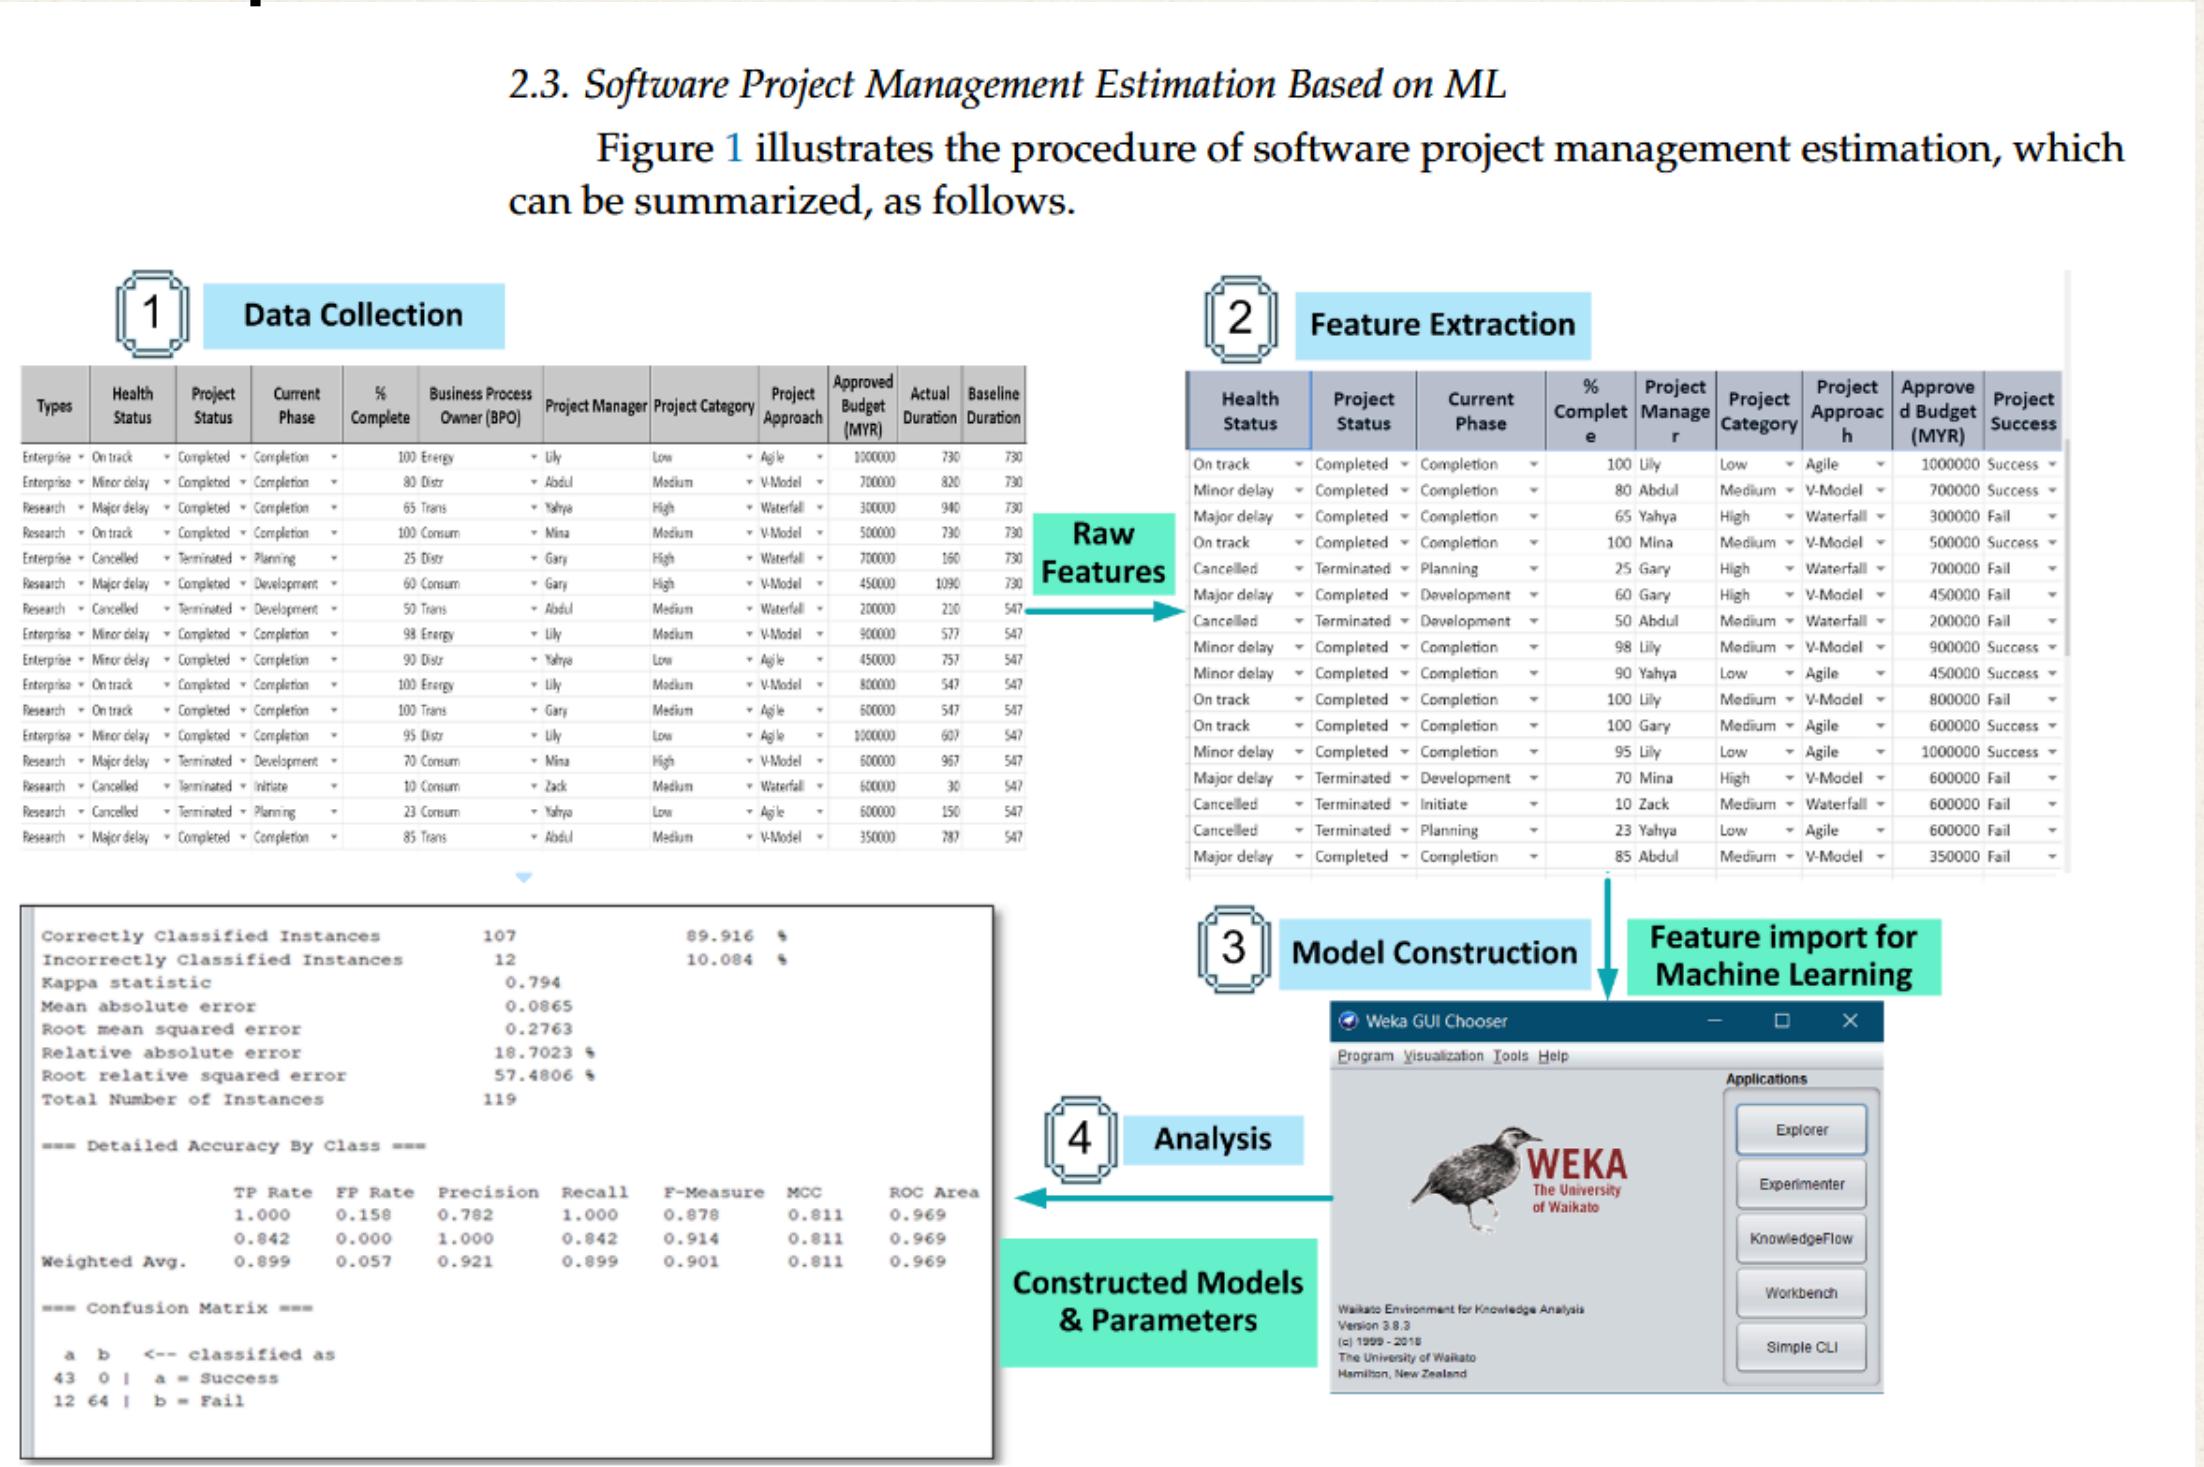


Figure 1. Example of Methodology for Developing Software Project Management Estimation.

Kajian ini menunjukkan bahwa riset tentang Machine Learning (ML) dalam Software Project Management (SPM) telah berkembang pesat, dengan fokus utama pada estimasi upaya (effort estimation) dan manajemen resiko (risk management) menggunakan algoritma seperti Artificial Neural Networks (ANN), Fuzzy Logic, Genetic Algorithms, dan Regresi. Penelitian ini memberikan gambaran awal tantangan, peluang, dan rekomendasi untuk mengoptimalkan penggunaan ML dalam estimasi manajemen proyek perangkat lunak.

Namun, masih banyak algoritma ML yang belum dikaji secara mendalam, dan ada perbedaan pendapat tentang cara mengukur perkembangan proyek. Penelitian lebih lanjut dibutuhkan, terutama untuk estimasi berbasis risiko, penggunaan metode penyaringan standar, serta prediksi tingkat keterlibatan stakeholder. Kajian ini memberikan gambaran awal tentang tantangan, manfaat, dan rekomendasi penggunaan ML untuk meningkatkan akurasi estimasi proyek perangkat lunak.

SOTA

STATE OF THE ART METHODS

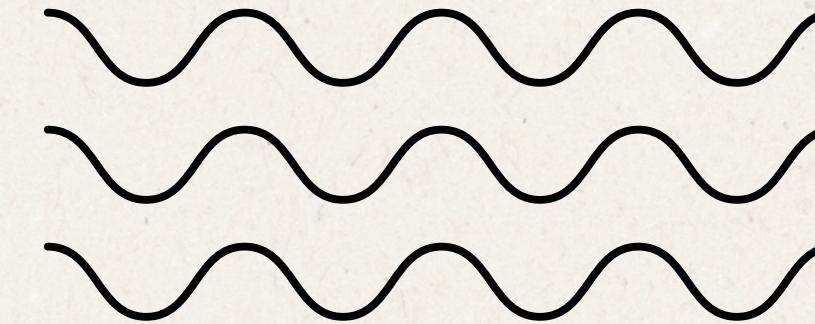
Paper	Methods	Strength	Gap
Cost Estimation (Shamim et al., 2025)	- ML: SVM, Decision Tree, Gradient Boosting - DL: ANN, CNN, LSTM - Hybrid: CBR-ANN, dll.	- Meningkatkan akurasi prediksi biaya - Cocok untuk data kompleks/non-linear - Hybrid efektif untuk proyek multifaset	- Perlu dataset besar & variatif - Biaya komputasi tinggi - Masih kurang transparan (XAI jarang dipakai)
Project Control & Monitoring (Santos et al., 2023)	- Earned Value Management (EVM) - Monte Carlo Simulation + ML - SHAP (XAI)	- Dua analisis: Forward (prediksi outcome) & Backward (penyebab deviasi) - XAI terintegrasi (SHAP) mempermudah interpretasi manajer proyek	- Komputasi SHAP berat (meski ada optimasi untuk tree & DL) - Lebih fokus ke monitoring, bukan otomatisasi assignment/resource
Software Project Management (SPM) (Zabil et al., 2020)	- ANN, Fuzzy Logic, Genetic Algorithm, Regression - KNN untuk data missing - Ensemble ML untuk effort estimation	- Fokus effort estimation & risk management - Mengurangi fault probability & meningkatkan project success ratio	- Banyak algoritma ML belum dieksplor - Belum ada standar evaluasi yang konsisten - Gap di stakeholder involvement & real-time integration



Technical Differentiation

Apa yang membedakan dari existing work?

05/10



- **Integrasi n8n + ML secara langsung**

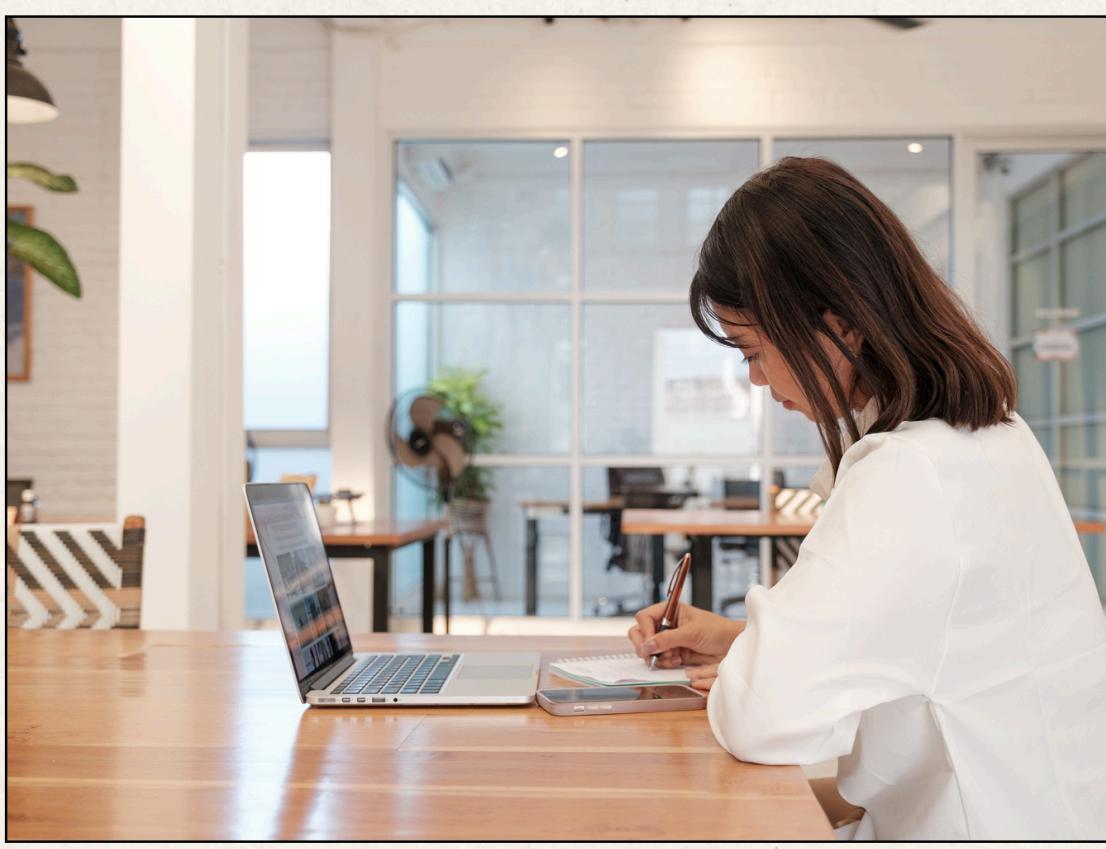
Model dipanggil oleh workflow automation (trigger, retrain, notifikasi).

- **Multi-task pipeline**

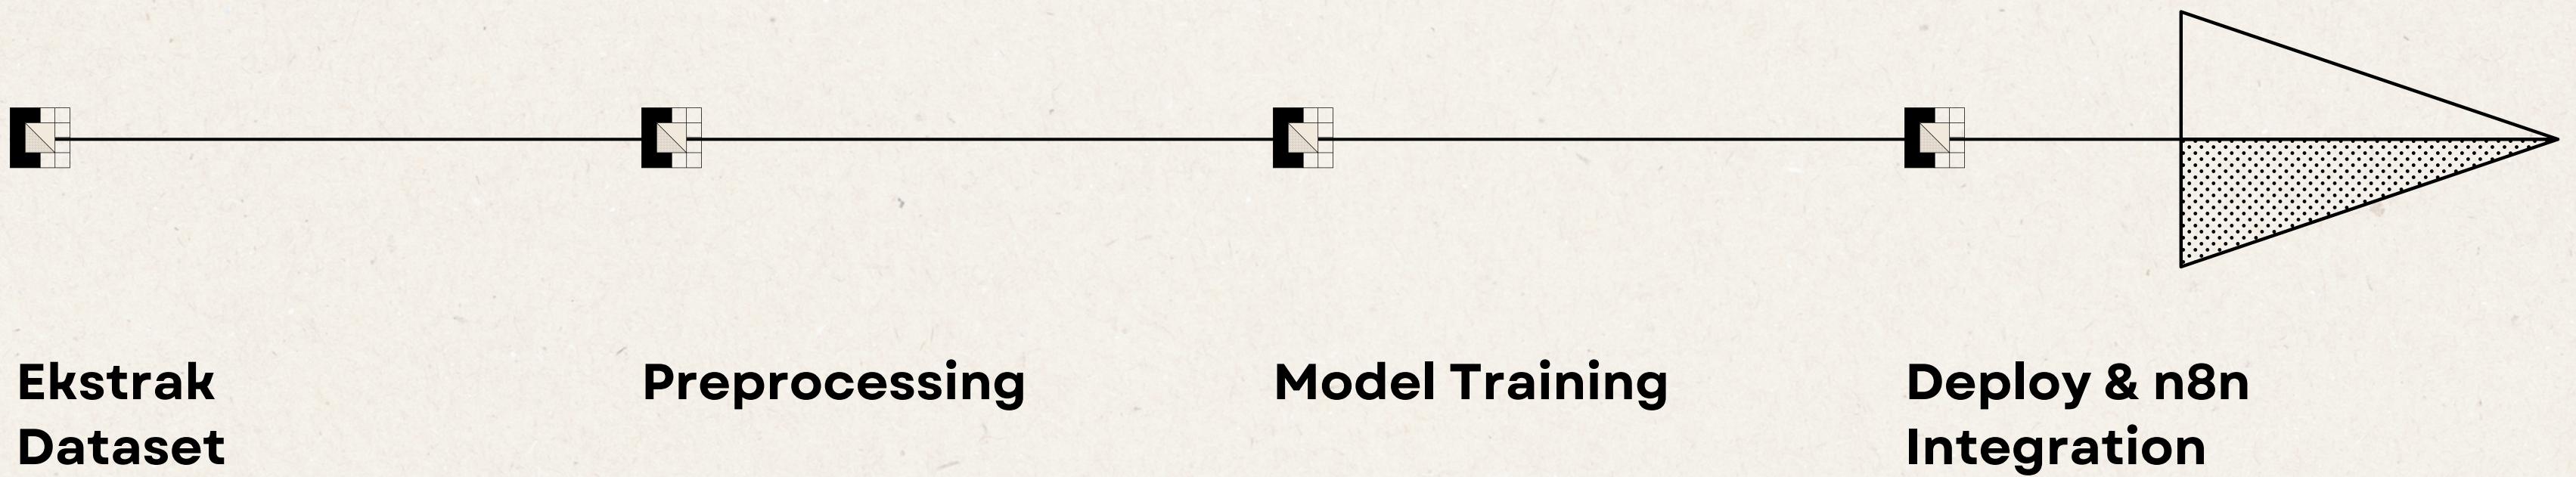
Assignment (RF/XGBoost), deadline (LSTM/DNN), resource optimizer (RL/LP) dalam satu arsitektur terkoordinasi.

- **Integrasi XAI**

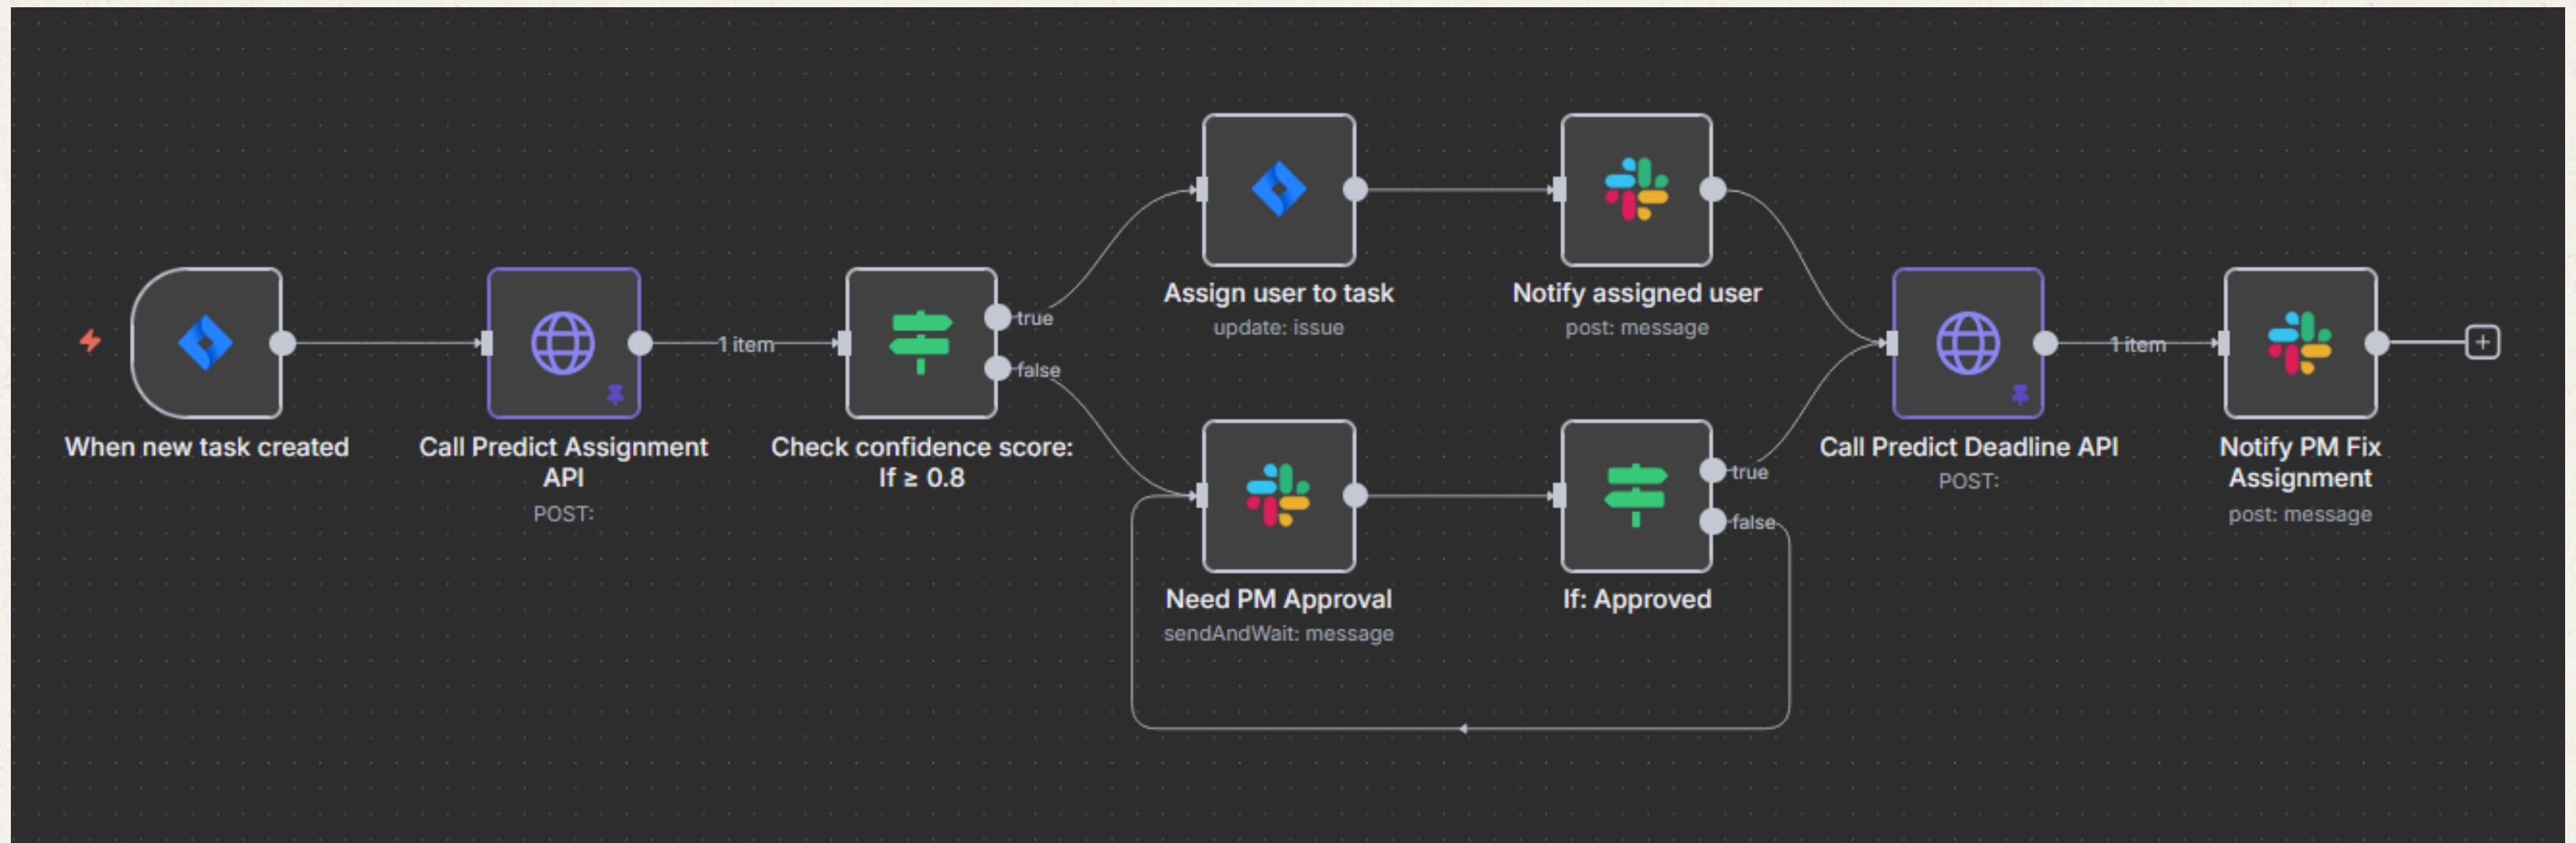
SHAP/LIME bukan hanya untuk analisis batch, tetapi untuk menjelaskan rekomendasi yang dikirim ke PM lewat n8n.



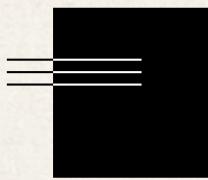
Rancangan Pengerjaan



Kasaran Workflow n8n



Experimental Design



Penjelasan Dataset

<https://www.kaggle.com/datasets/ka66ledata/project-management-risk-raw>

Dataset ini merupakan dataset manajemen proyek yang terdiri dari sekitar 4000 entri dengan total 51 class berbeda yang merepresentasikan berbagai jenis proyek. Jika hanya mengambil projek di departemen IT, jumlahnya menjadi 1381 entri. Dataset ini mencakup informasi penting seperti departemen, tingkat risiko, skor risiko, penanggung jawab proyek, serta atribut tambahan seperti tanggal mulai dan tanggal selesai.

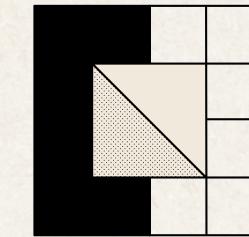
Metriks evaluasi

- Regression (deadline): MAE, MAPE, RMSE.
- Classification (delay / assignment multi-class): Accuracy, Precision, Recall, F1, Confusion Matrix.
- Resource allocation / RL: Reward function (utilization, cost deviation).

```
Shape: (4000, 51)
Columns: ['Project_ID', 'Project_Type', 'Team_Size', 'Project_Budget_USD', 'Estimated_Timeline_Months', 'Complexity_Score', 'Stakeholder_Count', 'Methodology_Used', 'Team_Experience_Level', 'Past_Similar_Projects', ... , 'Industry_Value']
```

	Project_ID	Project_Type	Team_Size	Project_Budget_USD	Estimated_Timeline_Months	Complexity_Score	Stakeholder_Count	Methodology_Used	Team_Experience_Level	Past_Similar_Projects	...	Industry_Value
0	PROJ_0001	Construction	32	1526276.55	32	9.70	16	Waterfall	Senior	3	...	E
1	PROJ_0002	Manufacturing	2	390790.15	9	2.72	9	Kanban	Mixed	0	...	M
2	PROJ_0003	Manufacturing	2	246674.76	6	2.04	7	Agile	Mixed	1	...	S
3	PROJ_0004	IT	12	1427830.63	17	7.54	16	Scrum	Mixed	0	...	E
4	PROJ_0005	Construction	24	1696746.64	24	6.68	17	Hybrid	Junior	0	...	M

Percobaan Training



- Deadline Regression (prediksi batas waktu): model (misal LSTM/DNN) memiliki MAE ~76–85 hari dan MAPE ~118%, artinya prediksi deadline masih cukup meleset dari aktual.
- Assignment (penugasan tugas ke anggota tim):
- Random Forest: presisi macro 0.879, akurasi 0.867 → cukup akurat.
- XGBoost/GB: presisi dan akurasi 1.0 → sempurna.
- Delay Classification (prediksi keterlambatan): presisi dan akurasi 1.0 → model dapat mendeteksi semua tugas terlambat dengan benar.
- Resource Allocation: contoh output menunjukkan rekomendasi penugasan tugas ke anggota tim, misal Task T001 -> Bob.
- XAI / Feature Importance (RF): faktor yang paling memengaruhi keputusan assignment adalah Total Workload Person dan Workload Share, sedangkan Tasks Per Project tidak berpengaruh.

```
14/14 ━━━━━━━━ 0s 5ms/step - loss: 100.5374 - mae: 100.5374 - val_loss: 75.9527 - val_mae: 75.9527
Epoch 30/30
14/14 ━━━━━━━━ 0s 5ms/step - loss: 100.0848 - mae: 100.0848 - val_loss: 75.9579 - val_mae: 75.9579
2/2 ━━━━━━ 0s 34ms/step
--- Assignment model evaluation ---
RandomForest precision (macro): 0.8790, accuracy: 0.8667
XGB/GB precision (macro): 1.0000, accuracy: 1.0000

--- Deadline regression evaluation ---
MAE (days): 85.8391
MAPE: 1.1835

--- Delay classification ---
Precision: 1.0000, Accuracy: 1.0000

--- Resource allocation sample (first 10) ---
Task T001 -> Bob
Task T002 -> Ivy
Task T003 -> Grace

--- XAI summary ---
Feature importance (RF):
Total Workload Person: 0.5435
Workload Share: 0.1195
Hours Spent: 0.0739
Task Duration: 0.0720
Task Complexity: 0.0643
Progress: 0.0481
Avg Project Priority: 0.0331
Budget Deviation: 0.0314
Priority_Num: 0.0141
Tasks Per Project: 0.0000
```

Thank you